

Análise Descritiva dos Dados da CTI Global

Professor: Rodinil da Silva Moreira Lisboa

Integrantes: Bruno Nobrega, Kaio Inglez, Mauricio Suster e Yuri Santana

1. Introdução

O objetivo desta entrega é fazer a análise descritiva dos dados enviados pela CTI Global para o projeto da Plataforma Analítica de Planejamento Financeiro. Calculamos as medidas de posição (média, mediana e moda) e de dispersão (variância e desvio padrão), montamos histogramas e boxplots e procuramos valores atípicos (outliers). Todos os cálculos e gráficos estão no notebook `Analise_Descritiva_CTI.ipynb`, feito no Google Colab com as bibliotecas `pandas` e `matplotlib`.

2. Base de dados

O arquivo `Demonstrativo Fecap v3.csv` tem 1.002.000 linhas. Cada linha é uma conta de um demonstrativo financeiro (balanço, DRE ou fluxo de caixa) de um ano e de um cenário. São 12 anos, 1.200 cenários simulados e 69 contas, ou seja, 14.400 demonstrativos completos de uma empresa concessionária. Para a análise escolhemos cinco variáveis: Receita, Custos, EBITDA e Lucro Líquido (da DRE) e Caixa (conta Disponível do balanço). Os valores foram convertidos para R\$ milhões. No arquivo os custos aparecem com sinal negativo, então invertemos o sinal para facilitar a leitura. As linhas sem nome de conta (linhas de separação do arquivo) foram removidas.

3. Medidas de posição e dispersão

A Tabela 1 mostra as estatísticas das cinco variáveis considerando as 14.400 observações. Como os valores são contínuos e quase não se repetem, a moda foi calculada como a classe mais frequente, dividindo cada variável em 20 faixas iguais.

Variável	Média	Mediana	Moda (classe)	Variância	Desvio padrão	Mínimo	Máximo
Receita	7.913	7.337	6.193 a 6.635	2.783.660	1.668	5.752	14.590
Custos	1.205	1.216	1.187 a 1.217	13.436	116	861	1.455
EBITDA	6.505	5.938	4.792 a 5.264	3.293.554	1.815	4.320	13.761
Lucro Líquido	3.357	2.979	2.312 a 2.641	1.776.101	1.333	1.653	8.234
Caixa	1.136	1.088	-21 a 404	725.781	852	-13	8.329

Tabela 1 – Medidas de posição e dispersão (R\$ milhões)

A média da Receita (R\$ 7.913 milhões) é maior que a mediana (R\$ 7.337 milhões), e a moda fica ainda mais abaixo (entre R\$ 6.193 e 6.635 milhões). Isso mostra uma distribuição assimétrica à direita: a maior parte dos valores está na faixa mais baixa e alguns valores bem altos puxam a média para cima. O mesmo acontece com o EBITDA e com o Lucro Líquido. Os Custos são a variável mais estável: média e mediana quase iguais e desvio padrão de apenas R\$ 116 milhões. O Caixa é a variável com maior variação relativa: o desvio padrão (R\$ 852 milhões) é quase do tamanho da média (R\$ 1.136 milhões).

Como os dados são de 12 anos, também calculamos a média por ano (Tabela 2). A receita cresce quase todos os anos, só cai no Ano 2, e dá um salto no Ano 12, que é o último ano da

concessão. O caixa não segue uma tendência: cai bastante nos Anos 5, 6 e 7, cresce até o Ano 11 e cai de novo no Ano 12.

Ano	Receita	Lucro Líquido	Caixa
1	6.679	2.416	1.118
2	6.090	1.967	878
3	6.255	2.113	1.591
4	6.514	2.302	966
5	6.846	2.635	257
6	7.249	2.951	235
7	7.674	3.142	381
8	8.166	3.398	1.262
9	8.633	3.668	1.713
10	9.171	4.133	1.998
11	9.723	4.654	2.791
12	11.962	6.900	440

Tabela 2 – Média por ano (R\$ milhões)

4. Histogramas e boxplots




Figura 1 – Histogramas das cinco variáveis

Os histogramas têm vários picos porque juntam os 12 anos, e cada ano tem um nível diferente de receita, EBITDA e lucro. O pico isolado à direita nessas três variáveis é o Ano 12. O histograma do Caixa é concentrado à esquerda (a maioria das observações fica abaixo de R\$ 2.000 milhões) com uma cauda longa à direita.




Figura 2 – Boxplots das cinco variáveis




Figura 3 – Boxplots por ano da Receita, do Lucro Líquido e do Caixa

Nos boxplots por ano fica claro que, dentro de um mesmo ano, a Receita e o Lucro variam muito pouco entre os 1.200 cenários (as caixas são estreitas) e crescem ao longo do tempo. Já o Caixa tem caixas mais largas e muitos pontos fora dos limites, principalmente nos Anos 8 a 11, o que mostra que a incerteza da simulação está concentrada no caixa e não na receita.

5. Valores atípicos

Usamos a regra do boxplot: um valor é atípico quando fica abaixo de $Q1 - 1,5 \times IQR$ ou acima de $Q3 + 1,5 \times IQR$ ($IQR = Q3 - Q1$). A Tabela 3 mostra o resultado para cada variável.

Variável	Limite inferior	Limite superior	Qtde de atípicos	% do total	Anos em que aparecem
Receita	3.181	12.204	140	0,97%	12
Custos	788	1.632	0	0,00%	—
EBITDA	2.119	10.235	1.190	8,26%	12
Lucro Líquido	191	5.908	1.190	8,26%	12
Caixa	-1.733	3.822	33	0,23%	9, 10 e 11

Tabela 3 – Valores atípicos pela regra do IQR (R\$ milhões)

Os atípicos de Receita, EBITDA e Lucro Líquido são todos do Ano 12, o ano de encerramento da concessão, em que os valores são bem maiores que nos outros anos. Os Custos não têm nenhum valor atípico. No Caixa, os 33 atípicos são cenários que acumularam muito caixa nos Anos 9, 10 e 11. Como cada ano tem um nível diferente, repetimos o teste do Caixa dentro de cada ano: encontramos 2.320 valores atípicos e 2.318 deles são dos cenários 1001 a 1200. Olhando esses cenários, a receita varia mais e o caixa muitas vezes chega a zero. Não parece erro nos dados, e sim um grupo de cenários mais pessimistas dentro da simulação.

6. Conclusão

- A receita cresce ao longo dos 12 anos (de R\$ 6,7 bilhões para R\$ 11,9 bilhões em média), com queda só no Ano 2. Os custos ficam praticamente estáveis, entre R\$ 1,0 e 1,4 bilhão.
- As distribuições de receita, EBITDA e lucro são assimétricas à direita (média maior que a mediana) por causa do Ano 12, que também concentra os valores atípicos.
- Dentro de cada ano, receita e lucro variam pouco entre os cenários; o caixa é a variável com maior variabilidade.
- Os cenários 1001 a 1200 se comportam de forma diferente dos demais, principalmente no caixa. Vamos levar isso em conta na próxima entrega, quando fizermos a regressão.