

Coleta, Limpeza e Integração dos Dados

PI Ciência de Dados – Entrega 01

Professor: Eduardo Savino Gomes

Integrantes: Bruno Nobrega, Kaio Inglez, Mauricio Suster e Yuri Santana

1. Introdução

Esta entrega apresenta a primeira etapa do processo de Ciência de Dados do projeto: identificar a fonte, coletar os dados, descrevê-los, explorá-los e prepará-los (seleção, limpeza, uniformização, integração, derivação e formatação). O resultado é uma base analítica única que será usada na análise estatística, nos KPIs financeiros e no dashboard da Entrega 02. Todo o processo está no notebook Preparacao_Dados_CTI.ipynb, feito no Google Colab com Python e pandas.

2. Identificação da fonte de dados

Item	Descrição
Fonte	CTI Global (empresa parceira do projeto)
Arquivo	Demonstrativo Fecap v3.csv, enviado dentro de DADOS_FECAP.zip (75 MB; 9 MB compactado)
Formato	CSV sem cabeçalho, separador ponto e vírgula, decimal com vírgula, codificação ISO-8859-1 (latin1)
Conteúdo	Balanco patrimonial (BAL), Demonstração do Resultado (DRE) e Fluxo de Caixa (FLU) de uma empresa concessionária
Período e granularidade	12 anos (Ano 1 a Ano 12, sem datas de calendário); uma linha por conta × ano × cenário, com 1.200 cenários simulados
Unidade	Reais (R\$) nominais
Condições de uso	Dados simulados, sem dados pessoais; uso restrito ao projeto, sem publicação em repositório aberto

Tabela 1 – Catálogo da fonte de dados

Não usamos fontes externas nesta entrega. Pensamos em cruzar os dados com indicadores econômicos (IPCA, Selic), mas o arquivo não tem datas de calendário, só "Ano 1" a "Ano 12", então não seria possível alinhar os períodos de forma confiável.

3. Coleta e descrição dos dados

O arquivo foi carregado no Colab por upload e lido inteiro como texto, sem alterações (camada raw). Ele tem 1.002.000 linhas e 4 colunas, às quais demos os nomes ano, cenário, conta e valor. Cada linha é o valor de uma conta contábil em um ano de um cenário. São 69 contas diferentes, distribuídas em três blocos:

Bloco	Demonstrativo	Linhas	Exemplos de contas
BAL	Balanco patrimonial	584.400	Total do Ativo, Disponível, Ativo Circulante, Empréstimos, Patrimônio Líquido
DRE	Demonstração do resultado	201.600	Receita, Tributos, Custos, EBITDA, Resultado Financeiro, Resultado Líquido
FLU	Fluxo de caixa	172.800	Saldo Inicial, Investimentos, Distribuição para Acionista, Geração de Caixa, Saldo Final
(sem nome)	Linhas de controle	43.200	Check do balanço (Ativo + Passivo ≈ 0) e linhas separadoras com valor zero

Tabela 2 – Estrutura do arquivo

4. Exploração inicial

- Cada cenário tem 72 linhas por ano, com duas exceções: os Anos 1 e 2 têm 71 (a conta Dividendos Antecipados só aparece a partir do Ano 3) e o Ano 12 tem 45, porque é o balanço de encerramento da concessão (não tem Patrimônio Líquido nem dívidas de longo prazo).
- Os valores estão no formato brasileiro (1.234.567,89) e seguem uma convenção de sinais: ativo e receitas positivos; passivo, patrimônio líquido e despesas negativos.

- Não há valores vazios na coluna de valor nem linhas repetidas (mesmo cenário, ano e conta).
- A linha de empréstimos de curto prazo fica positiva a partir do Ano 4: o modelo acumula ali as amortizações da dívida, em vez de reduzir a linha de longo prazo.
- O EBITDA informado pela CTI é, em média, R\$ 300,8 milhões maior que o EBITDA calculado pelas outras linhas da DRE (resultado operacional + outros resultados + depreciação e amortização).

5. Seleção dos dados

Das 69 contas, selecionamos 20 que respondem às perguntas do projeto (receita, custos, margens, resultado, caixa, dívida e patrimônio) e que alimentam os KPIs e o dashboard: 10 da DRE (receita, tributos, custos, depreciação e amortização, resultado operacional, outros resultados, resultado financeiro, IR/CS, resultado líquido e EBITDA reportado), 6 do balanço (disponível, ativo circulante, ativo total, empréstimos de curto e de longo prazo e patrimônio líquido) e 4 do fluxo de caixa (investimentos, distribuição para acionistas, geração de caixa e saldo final). Todos os 1.200 cenários e os 12 anos foram mantidos.

6. Limpeza e uniformização

Problema encontrado	Quantidade	Tratamento
Arquivo sem cabeçalho	4 colunas	Definimos os nomes ano, cenário, conta e valor
Linhas sem nome de conta (check e separadores)	43.200 linhas	Removidas; o check foi usado só para conferir o balanço
Espaço duplo no nome da conta (ex.: "BAL - Patrimônio Líquido")	9 contas	Espaços padronizados; sem isso a conta não era encontrada
Valor em texto no formato brasileiro	958.800 valores	Convertido para número (retira o ponto do milhar e troca a vírgula por ponto)
Ano e cenário como texto ("Ano 3", "Total Cen_00001")	todas as linhas	Convertidos para números inteiros (3 e 1)
Despesas e passivos com sinal negativo	7 variáveis	Sinal invertido para ficarem positivos
Empréstimos inexistentes no Ano 12	1.200 linhas	Tratados como zero (dívida já quitada)
Patrimônio Líquido inexistente no Ano 12	1.200 linhas	Mantido vazio (não inventamos valor)
Caixa negativo	1 caso (-R\$ 12,6 mi)	Mantido e registrado (cenário 1069, Ano 12)

Tabela 3 – Problemas de qualidade e tratamentos (camada staging)

7. Integração e derivação

Os três demonstrativos vêm empilhados no mesmo arquivo. Para integrá-los, transformamos as contas em colunas, e a base passou a ter uma linha por cenário e ano (14.400 linhas). Conferimos se os demonstrativos batem entre si: o saldo final do fluxo de caixa é exatamente igual ao disponível do balanço em todas as linhas (diferença zero) e o balanço fecha (Ativo + Passivo), com diferença máxima de R\$ 0,03, que é só arredondamento.

Depois criamos variáveis derivadas:

- dívida bruta = -(empréstimos de curto prazo + empréstimos de longo prazo), somando as duas linhas para corrigir o efeito das amortizações acumuladas; dívida líquida = dívida bruta – caixa;
- receita líquida = receita – tributos; EBITDA = resultado operacional + outros resultados + depreciação e amortização;
- margem EBITDA e margem líquida (sobre a receita líquida) e custos sobre a receita;
- grupo do cenário (1–1000 ou 1001–1200), porque a análise descritiva mostrou que os dois grupos se comportam de forma diferente.

8. Formatação e base final

Os valores em reais foram convertidos para R\$ milhões, as margens ficaram em fração (0,79 = 79%) e as colunas receberam nomes em minúsculas e sem acento. Colunas usadas só para conferência (saldo final do fluxo e as duas linhas de empréstimo) foram retiradas. A base final foi salva em dados/processed/base_cti_processada.csv (separador ponto e vírgula, decimal com vírgula), seguindo as camadas raw (arquivo original), staging (dados limpos no formato longo) e processed (base analítica).

Coluna(s)	Descrição	Unidade
cenario, ano	Chaves da base: número do cenário (1 a 1.200) e do ano (1 a 12)	inteiro
grupo_cenario	Cenários 1–1000 ou 1001–1200	texto
receita, tributos, receita_liquida, custos	Receita bruta, tributos sobre a receita, receita líquida e custos operacionais	R\$ mi
ebitda, ebitda_reportado	EBITDA calculado e EBITDA informado pela CTI	R\$ mi
depreciacao_amortizacao, resultado_operacional, outros_resultados	Linhas da DRE usadas no cálculo do EBITDA	R\$ mi
resultado_financeiro, ir_cs, lucro_liquido	Resultado financeiro, imposto de renda/CSLL e lucro líquido	R\$ mi
caixa, ativo_circulante, ativo_total	Contas do ativo no balanço	R\$ mi
divida_bruta, divida_liquida, patrimonio_liquido	Dívida (derivada) e patrimônio líquido (vazio no Ano 12)	R\$ mi
investimentos, dividendos, geracao_caixa	Linhas do fluxo de caixa	R\$ mi
margem_ebitda, margem_liquida, custos_sobre_receita	Indicadores derivados sobre a receita líquida	fração

Tabela 4 – Dicionário de dados da base final (14.400 linhas × 27 colunas)




Figura 1 – Mediana por ano das principais variáveis da base final

A Figura 1 resume a base pronta: a receita líquida e o EBITDA crescem ao longo da concessão (com queda no Ano 2), a dívida é amortizada até zerar no Ano 12 e o caixa oscila, caindo nos Anos 5 a 7 e no último ano, quando é distribuído aos acionistas.

9. Conclusão

Partimos de um arquivo de 1.002.000 linhas em formato longo, sem cabeçalho e com linhas de controle, e chegamos a uma base analítica de 14.400 linhas e 27 colunas, sem duplicidades e sem valores vazios (exceto o patrimônio líquido do Ano 12, que não existe). Os demonstrativos foram conferidos entre si e todo o processo pode ser repetido pelo notebook a partir do arquivo original. Como próximos passos, a base será usada na regressão e no dashboard, e vamos confirmar com a CTI a diferença do EBITDA reportado e a forma como a dívida é registrada no modelo.