FECAP – Ciência da Computação – 4º semestre – Projeto Interdisciplinar – 2º semestre de 2026
Projeto: CTI – Plataforma Analítica de Planejamento Financeiro (parceira: CTI Global)

Análise de Regressão dos Dados

Análise Inferencial de Dados – Entrega 02

Professor: Rodinil da Silva Moreira Lisboa
Integrantes: Bruno Nobrega, Kaio Inglez, Mauricio Suster e Yuri Santana

1. Introdução

Na Entrega 01 descrevemos os dados da CTI (média, desvio padrão, histogramas, boxplots e outliers). Nesta entrega ajustamos modelos de regressão linear para entender o que explica a diferença de lucro líquido entre os 1.200 cenários simulados. Interpretamos os coeficientes, avaliamos a qualidade do ajuste, fizemos os diagnósticos dos resíduos e registramos as limitações. Todo o código está no notebook Analise_Regressao_CTI.ipynb (roda no Google Colab enviando o DADOS_FECAP.zip).

2. Dados e variáveis

Usamos o arquivo Demonstrativo Fecap v3.csv (12 anos × 1.200 cenários). Para não misturar o efeito do tempo, já que a receita cresce ano a ano, a análise principal usa só o Ano 6 (meio da concessão), com n = 1.200 cenários. Os valores estão em R$ milhões.

Variável	Como foi calculada	Média (Ano 6)	Desvio padrão
lucro (y)	DRE - Resultado Líquido	2.950,9	71,0
receita_liq	DRE - Receita + DRE - Tributos	6.624,4	103,9
custos	DRE - Custos × (−1)	1.110,5	19,6
grupo2 (dummy)	1 se cenário 1001 a 1200; 0 se 1 a 1000	0,17	–

Tabela 1 – Variáveis usadas nos modelos

A dummy grupo2 entrou porque na Entrega 01 vimos que os cenários 1001 a 1200 se comportam diferente. A correlação do lucro com a receita líquida é 0,92, com os custos é 0,27 e com o grupo2 é −0,38. A Figura 1 mostra que os cenários 1 a 1000 ficam concentrados num ponto, enquanto os cenários 1001 a 1200 se espalham em duas retas. É nesse grupo que a receita mais varia, como se a CTI tivesse mudado uma variável de cada vez (análise de sensibilidade).

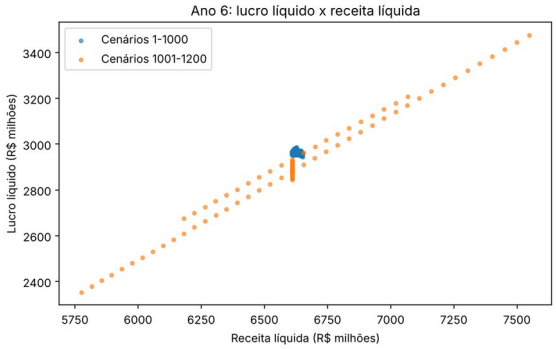


Figura 1 – Lucro líquido x receita líquida no Ano 6

3. Modelos ajustados

Ajustamos dois modelos por mínimos quadrados ordinários (OLS), com a biblioteca statsmodels:

- **Modelo 1 (simples):** lucro = β0 + β1·receita_liq + ε
- **Modelo 2 (múltiplo):** lucro = β0 + β1·receita_liq + β2·custos + β3·grupo2 + ε

Coeficiente	Modelo 1	IC 95% (M1)	Modelo 2	IC 95% robusto (M2)	p-valor
Intercepto	−1.228,8	−1.326,9 a −1.130,8	−773,2	−840,7 a −705,7	< 0,001
receita_liq	0,631	0,616 a 0,646	0,655	0,646 a 0,664	< 0,001
custos	–	–	−0,542	−0,559 a −0,526	< 0,001
grupo2	–	–	−72,1	−74,4 a −69,9	< 0,001

Tabela 2 – Coeficientes estimados (Ano 6, n = 1.200). No Modelo 2 o IC usa erros robustos HC3

4. Interpretação dos coeficientes

- **Receita líquida:** no Modelo 1, cada R$ 1 milhão a mais de receita está associado a R$ 0,63 milhão a mais de lucro. No Modelo 2, mantendo custos e grupo fixos, o valor sobe para R$ 0,655 milhão. Isso é quase 1 − 34% = 0,66, ou seja, o que sobra da receita depois do IR e da CSLL (alíquota efetiva de 34,4% no Ano 6). O modelo "encontrou" a carga de imposto da empresa.
- **Custos:** R$ 1 milhão a mais de custos reduz o lucro em R$ 0,54 milhão. O sinal é o esperado. O valor fica um pouco abaixo de 0,66 em módulo, provavelmente porque outras contas fora do modelo variam junto com os custos.
- **Grupo 1001–1200:** com a mesma receita e os mesmos custos, esses cenários têm em média R$ 72 milhões a menos de lucro. Nos dados, eles têm depreciação maior (R$ 920 contra R$ 846 milhões) e resultado financeiro pior (−R$ 237 contra −R$ 200 milhões). Descontado o imposto, essas diferenças dão cerca de R$ 74 milhões, perto do coeficiente.
- **Intercepto:** não tem interpretação prática, porque receita zero está muito fora dos dados. Ele só posiciona a reta.

5. Qualidade do ajuste e validação

Para ver se o modelo funciona em dados que ele não viu, separamos 80% dos cenários para treino (960) e 20% para teste (240), com sorteio fixo (random_state = 42).

Métrica	Modelo 1	Modelo 2
R^2	0,854	0,989
R^2 ajustado	0,854	0,989
AIC	11.329,5	8.213,0
RMSE (R$ milhões)	27,1	7,4
Teste F (p-valor)	< 0,001	< 0,001
R^2 na base de teste	0,748	0,987
RMSE na base de teste	26,6	6,1

Tabela 3 – Métricas dos modelos (Ano 6)

A receita sozinha já explica 85% da variação do lucro. Com custos e a dummy de grupo o R^2 vai para 98,9% e o erro típico cai de R$ 27,1 para R$ 7,4 milhões (0,25% do lucro médio). O Modelo 2 manteve o desempenho no teste. O Modelo 1 piorou mais (R^2 de 0,854 para 0,748), porque depende de poucos cenários extremos.

6. Diagnóstico dos resíduos (Modelo 2)

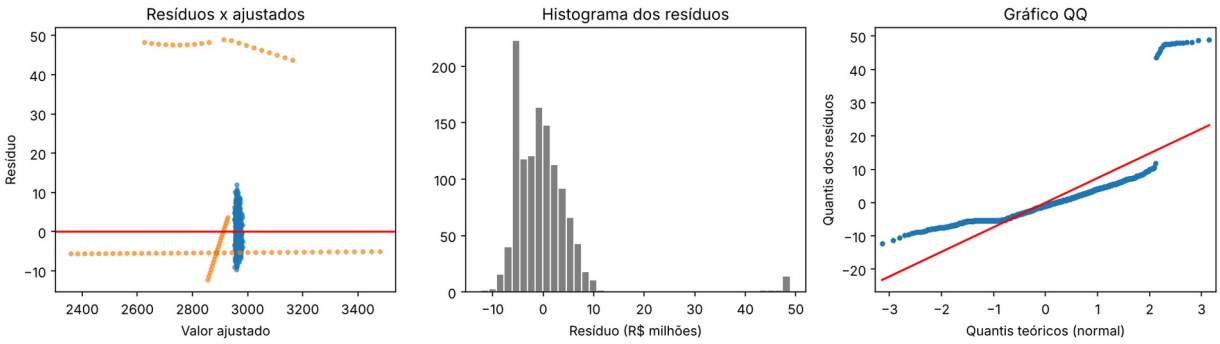


Figura 2 – Resíduos x valores ajustados, histograma e gráfico QQ dos resíduos

- **Homocedasticidade:** o teste de Breusch-Pagan deu estatística 114,2 e p-valor ≈ 0, então rejeitamos variância constante. Os resíduos do grupo 1001–1200 são bem mais espalhados (desvio padrão de 15,8 contra 4,0).
- **Normalidade:** o teste de Jarque-Bera rejeitou a normalidade (assimetria 4,3 e curtose 28). A cauda à direita vem de 20 cenários seguidos (1069 a 1088), com lucro R$ 43 a 49 milhões acima do previsto.
- **Multicolinearidade:** os VIF ficaram entre 1,08 e 1,21, bem abaixo de 5. As variáveis não repetem informação.

- **Correção:** refizemos o modelo com erros-padrão robustos (HC3). O erro-padrão da receita foi de 0,0022 para 0,0045, mas todos os coeficientes continuaram significativos ($p < 0,001$). Com $n = 1.200$, as estimativas continuam confiáveis mesmo sem normalidade.

7. O modelo vale para os outros anos?

Repetimos o Modelo 2 nos 12 anos (Figura 3). O R^2 ficou entre 0,94 e 0,995. O coeficiente da receita é muito estável, entre 0,62 e 0,66, sempre perto de 0,66. Já o coeficiente dos custos não é estável: vai de −0,59 a +0,45 e nos Anos 3 e 12 nem é significativo. Os custos variam pouco entre os cenários e andam junto com outras contas, então o modelo não separa bem o efeito deles. O efeito do grupo 1001–1200 é negativo em todos os anos (de −72 a −211 milhões).

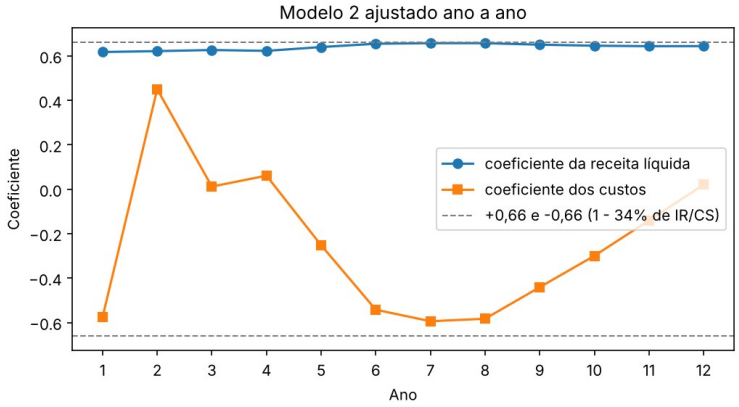


Figura 3 – Coeficientes da receita e dos custos no Modelo 2, ano a ano

8. Limitações

- Os dados são simulados pela CTI e o lucro sai da própria DRE, então a relação é quase contábil (com todas as contas da DRE o R^2 seria 1). Por isso usamos poucas variáveis.
- Correlação não é causa: o modelo mostra associação dentro da simulação, não o efeito real de mudar a receita na empresa.
- Os resíduos não são normais e a variância muda entre os grupos. Os erros robustos ajudam, mas um modelo separado por grupo poderia ser melhor.
- Analisamos um ano por vez porque os 12 anos do mesmo cenário não são independentes. Depreciação e resultado financeiro ficaram fora do modelo e isso aparece no coeficiente dos custos.

9. Conclusão

A receita líquida é a principal variável para explicar o lucro entre os cenários: de cada R$ 1 a mais de receita, cerca de R$ 0,65 vira lucro, valor estável em todos os anos e coerente com a alíquota de IR/CS de 34%. O modelo múltiplo (receita, custos e grupo) explica 98,9% da variação do lucro no Ano 6 e funciona bem nos dados de teste. Os cenários 1001 a 1200 têm lucro menor com a mesma receita, por causa de depreciação maior e resultado financeiro pior. Os diagnósticos mostraram heterocedasticidade e resíduos não normais, o que tratamos com erros robustos e registramos como limitação.